

DIVINE: analýza programů v C++

Vladimír Štill



Masarykova univerzita
Brno, Česká republika

16. září 2017



DIVINE je nástroj na analýzu programů v C a C++

- historicky býval zaměřený převážně na verifikace paralelních/distribovaných systémů
- nyní především důraz na podporu C a C++ a na hledání těžko-nalezitelných problémů



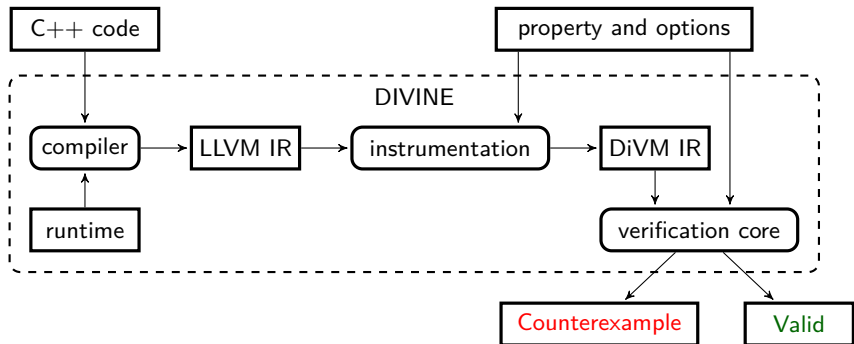
DIVINE je nástroj na analýzu programů v C a C++

- historicky býval zaměřený převážně na verifikace paralelních/distribuovaných systémů
- nyní především důraz na podporu C a C++ a na hledání těžko-nalezitelných problémů
- memory safety, assertion safety, problémy související s paralelismem (deadlocky, data race, memory modely)
- simulace chyb

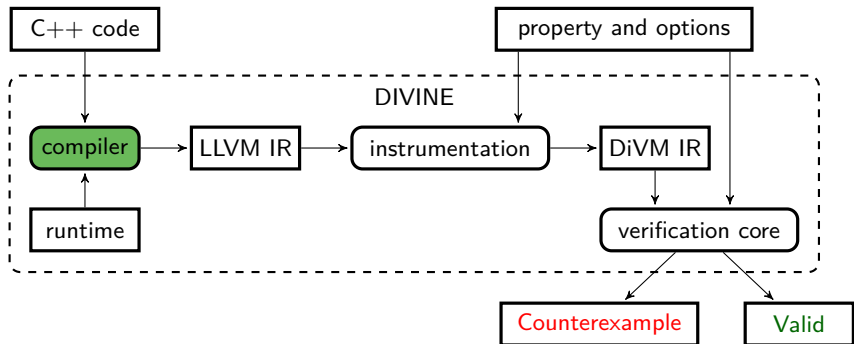


DIVINE je nástroj na analýzu programů v C a C++

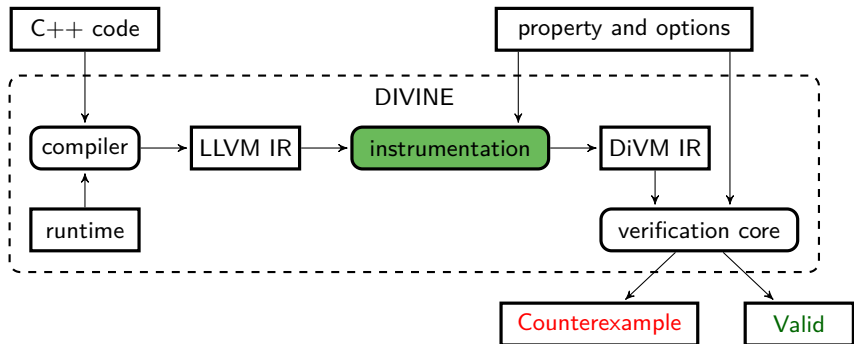
- historicky býval zaměřený převážně na verifikace paralelních/distribovaných systémů
- nyní především důraz na podporu C a C++ a na hledání těžko-nalezitelných problémů
- memory safety, assertion safety, problémy související s paralelismem (deadlocky, data race, memory modely)
- simulace chyb
- rozsáhlá jazyková podpora, podpora části POSIX



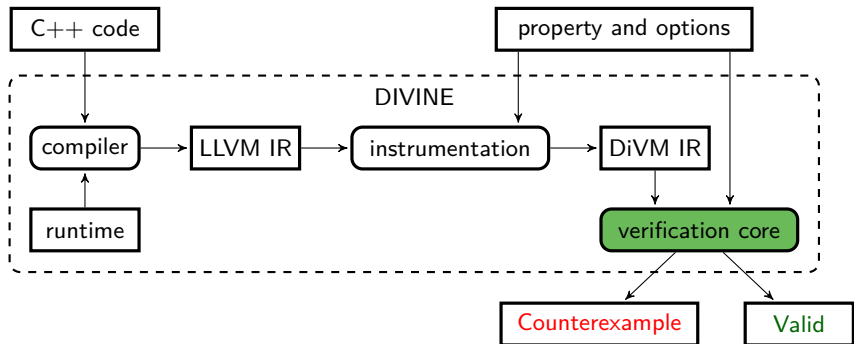
- DIVINE je postavený nad LLVM: využívá kompilátor clang a analyzuje LLVM bitkód



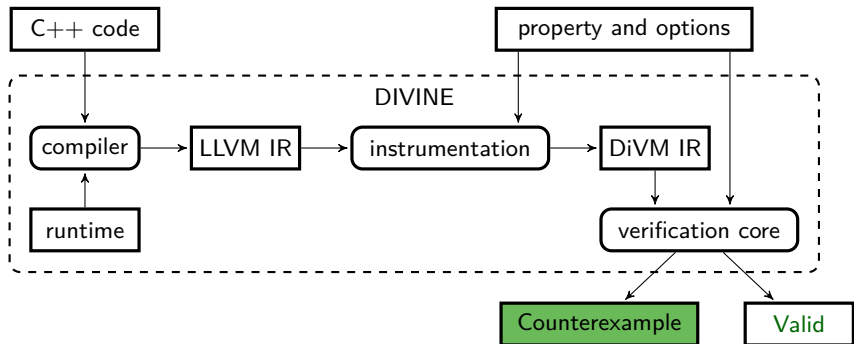
- kompilátor je clang integrovaný jako knihovna do DIVINE
- překládá nejen uživatelův program ale i knihovny, které program může volat



- část instrumentace je nutná pro chod DIVINE: sledování přístupu k paměti, detekce cyklů v control flow.
- část rozšiřuje funkcionalitu: symbolická verifikace, memory modely



- interpret LLVM s grafovou pamětí, který zajišťuje samotné spouštění programu
- algoritmus pro prohledávání stavového prostoru



- DIVINE dále obsahuje simulátor/debugger pro procházení běhů programu




- DIVINE používá vlastní interpret LLVM
 - DIVINE Virtual Machine = DiVM



- DIVINE používá vlastní interpret LLVM
 - DIVINE Virtual Machine = DiVM
- interpret musí být velmi striktní
 - kontrola přístupu k paměti, ...
- také musí být pokud možno rychlý
- musí umožnit uložit snapshot stavu programu
- musí umožnit spustit vše potřebné pro běh programu

- LLVM IR je nejprve přeložen do interní reprezentace: DiVM IR
- přidává k LLVM IR: alokace paměti, nízkoúrovňová manipulace zásobníku, hlášení chyb, ...
- DiVM pracuje s pamětí reprezentovanou jako graf



Obrázek 1: Paměť jako graf



- programy nejsou uzavřené, používají externí hlavičkové soubory, externí knihovny



- programy nejsou uzavřené, používají externí hlavičkové soubory, externí knihovny
- používat systémové hlavičkové soubory je nebezpečné



- programy nejsou uzavřené, používají externí hlavičkové soubory, externí knihovny
- používat systémové hlavičkové soubory je nebezpečné

```
$ ./symbiotic mem_heap_bug01.c  
cc: /usr/include/stdlib.h:33:10: fatal error:  
    'stddef.h' file not found  
cc: 1 warning and 1 error generated.
```



- programy nejsou uzavřené, používají externí hlavičkové soubory, externí knihovny
- používat systémové hlavičkové soubory je nebezpečné

```
$ ./symbiotic mem_heap_bug01.c  
cc: /usr/include/stdlib.h:33:10: fatal error:  
    'stddef.h' file not found  
cc: 1 warning and 1 error generated.
```

- proto si s sebou DIVINE nese knihovny
 - standardní knihovny C a C++
 - POSIX threads



- DIVINE překládá C/C++ soubory pomocí integrovaného kompilátoru
 - clang jako knihovna
- knihovny jsou přeloženy při překladu DIVINE
- kompilátor je přilinkuje k programu



- DIVINE překládá C/C++ soubory pomocí integrovaného kompilátoru
 - clang jako knihovna
- knihovny jsou přeloženy při překladu DIVINE
- kompilátor je přilinkuje k programu
- dále je třeba poskytnout programu plánování vláken, procesů, případně simulaci práce se soubory, ...



- DIVINE překládá C/C++ soubory pomocí integrovaného kompilátoru
 - clang jako knihovna
- knihovny jsou přeloženy při překladu DIVINE
- kompilátor je přilinkuje k programu
- dále je třeba poskytnout programu plánování vláken, procesů, případně simulaci práce se soubory, ...
- to vše v DIVINE zajišťuje DiOS (DIVINE Operating System)



- `divine verify file.cpp [args...]`
- `divine check file.cpp [args...]`
 - méně striktní režim (neselhává alokace paměti, ...)



- `divine verify file.cpp [args...]`
- `divine check file.cpp [args...]`
 - méně striktní režim (neselhává alokace paměti, ...)
- ovlivnění kompilace:
 - `divine verify -std=c++14 file.cpp`
 - `-std=`, `-l`, přímo, další přepínače přes `-C`
 - `divine verify -C,-O3 file.cpp`



- `divine verify file.cpp [args...]`
- `divine check file.cpp [args...]`
 - méně striktní režim (neselhává alokace paměti, ...)
- ovlivnění kompilace:
 - `divine verify -std=c++14 file.cpp`
 - `-std=`, `-l`, přímo, další přepínače přes `-C`
 - `divine verify -C,-O3 file.cpp`
- oddělená kompilace a verifikace
 - `divine cc -almost-any-clang-flags file1.cpp file2.cpp`
 - `divine verify file1.bc`



- `divine sim file.cpp`
 - pro krokování programu od začátku
- `divine sim --load-report file.report.????`
 - načtení reportu z `verify/check`
 - jméno reportu je na konci výpisu z verifikace
 - automaticky skočí před chybu
 - na chybu se obvykle lze dostat přes příkaz `stepa`



- `up/down` – skákání po zásobníku
- `show VAR` – výpis hodnoty
 - `show .localvar`
 - `show $globals.globalvar`
- `backtrace`
 - `backtrace $state` pro všechna vlákna
- `step [--over] [--out]` – krokování po „příkazu“
- `stepi [--over] [--out]` – krokování po instrukci
- `stepa [--over] [--out]` – krokování po atomickém kroku
- `thread pid:tid` – výběr vlákna



- `rewind #stav` – návrat do předchozího stavu
- `start` – skok na začátek `main`
- `break file:line`
- `break function`
- `draw VAR`
- přidání okna se zdrojovým kódem
 - `setup --xterm src`
 - `setup --sticky "source --output-to src --clear-screen" --pygmentize`

DEMO:

- `ssh login@arke`
- `source /var/obj/divine-fakos`
- `git clone https://github.com/vlstill/presentations.git`
- `cd presentations/fakos_2017/demo`

Instrumentace – paměťové modely



- při běhu paralelních programů vstupují do hry specifika chování daného hardware
 - přeuspořádání instrukcí a cache paměti způsobují, že paměťové efekty vlákna nemusí být vidět v očekávaném pořadí
 - Intel x86 umí „jen“ pozdržovat zápisy, ale zachovává jejich pořadí
 - ARM umí přeuspořádat téměř libovolné nezávislé a některé závislé operace
- kompilátor rovněž může přeuspořádávat operace
- programátor musí správně využívat synchronizaci aby zabránil problémům s relaxovanou pamětí
 - `std::atomic` v C++



```
int x = 0, y = 0;

void thread1() { x = 1; y = 2; }
void thread2() {
    while ( y == 0 ) { }
    cout << "y = " << y << endl;
    cout << "x = " << x << endl;
}
```

Dosažitelné $x = 0 \wedge y = 2$?



```
int x = 0, y = 0;

void thread1() { x = 1; y = 2; }
void thread2() {
    while ( y == 0 ) { }
    cout << "y = " << y << endl;
    cout << "x = " << x << endl;
}
```

Dosažitelné $x = 0 \wedge y = 2$? **ano**

- nedefinované chování – může dělat cokoli
- thread2 může přecíst y jen jednou



```
volatile int x = 0, y = 0;

void thread1() { x = 1; y = 2; }
void thread2() {
    while ( y == 0 ) { }
    cout << "y = " << y << endl;
    cout << "x = " << x << endl;
}
```

Dosažitelné $x = 0 \wedge y = 2$? **ano**

- opět nedefinované chování
- na většině kompilátorů zajistí, že se y přečte v každé iteraci cyklu
- to však na některých platformách nestačí k zajištění korektnosti (ARM/POWER)



```
std::atomic< int > x = 0, y = 0;

void thread1() { x = 1; y = 2; }
void thread2() {
    while ( y == 0 ) { }
    cout << "y = " << y << endl;
    cout << "x = " << x << endl;
}
```

Dosažitelné $x = 0 \wedge y = 2$? **ne**

- garance atomického přístupu k x, y
- y načteno v každé iteraci cyklu
- procesor nesmí přeuspořádat atomické zápisy



- verifikační nástroje často neberou ohled na paměťový model
- v DIVINE používáme instrumentaci k zohlednění paměťového modelu



- verifikační nástroje často neberou ohled na paměťový model
- v DIVINE používáme instrumentaci k zohlednění paměťového modelu
- čtení a zápisy nahrazeny za funkce které simulují zpoždování operací
 - zpoždování zápisů pomocí store bufferů
 - předbírání zápisů je komplikovanější



```
int x = 0, y = 0;
```

```
void thread0() {  
    y = 1;  
    cout << "x = " << x;  
}
```

```
void thread1() {  
    x = 1;  
    cout << "y = " << y;  
}
```



```
int x = 0, y = 0;
```

```
void thread0() {  
    y = 1;  
    cout << "x = " << x;  
}
```

```
void thread1() {  
    x = 1;  
    cout << "y = " << y;  
}
```

main memory

0x04	0x08
x = 0	y = 0

thread 0



store y 1;
load x;

thread 1



store x 1;
load y;

store buffer for thread 0

--	--	--


store buffer for thread 1

--	--	--

```
int x = 0, y = 0;
```

```
void thread0() {
    y = 1;
    cout << "x = " << x;
}
```


```
void thread1() {
    x = 1;
    cout << "y = " << y;
}
```



```
int x = 0, y = 0;
```

```
void thread0() {  
    y = 1;  
    cout << "x = " << x;  
}
```


```
void thread1() {  
    x = 1;  
    cout << "y = " << y;  
}
```



```
int x = 0, y = 0;
```

```
void thread0() {
    y = 1;
    cout << "x = " << x;
}
```

```
void thread1() {
    x = 1;
    cout << "y = " << y;
}
```



```
int x = 0, y = 0;
```

```
void thread0() {
    y = 1;
    cout << "x = " << x;
}
```

```
void thread1() {
    x = 1;
    cout << "y = " << y;
}
```

